Análise Estatística Descritiva do Dataset de Eleições: Dinheiro de Campanha e Votos nas Eleições Brasileiras de 2014

Heitor Teixeira - 2651254
MBA: Ciência de dados
UNIFOR
Fortaleza, Brasil
heitor.mba.unifor@gmail.com

***Resumo*—Este trabalho apresenta uma análise estatística descritiva do dataset de Eleições Brasileiras de 2014 (D2), restrito aos candidatos a Deputado Federal. A base principal contém 6.353 candidaturas e foi enriquecida com informações auxiliares do Tribunal Superior Eleitoral (TSE), embora as análises centrais do relatório se concentrem nas variáveis *Gasto* e *Votos*, conforme solicitado na atividade. Foram construídos histogramas de gasto e votos para os estados RJ, GO e AM, gráficos de dispersão entre gasto e votos para os mesmos recortes, uma tabela de correlação por UF e uma tabela-resumo por estado com média, mediana, desvio-padrão, mínimo, máximo, Q1 e Q3. Os resultados mostram distribuições fortemente assimétricas à direita, o que justifica o uso de escala logarítmica nos histogramas e gráficos de dispersão. A correlação entre gasto e votos foi positiva em todas as 27 UFs analisadas, variando de $r = 0{,}475$ em São Paulo a $r = 0{,}902$ no Amazonas. Entre os estados selecionados, o Rio de Janeiro apresentou correlação moderada positiva ($r = 0{,}556$), Goiás correlação moderada positiva ($r = 0{,}605$) e o Amazonas correlação forte positiva ($r = 0{,}902$). Em nível nacional, a mediana de gasto (R$ 9.916) ficou muito abaixo da média (R$ 220.397), evidenciando forte concentração de recursos em poucas candidaturas.**

***Index Terms*—Estatística descritiva, eleições brasileiras, correlação de Pearson, histograma, escala logarítmica.**

I. Introdução

Este relatório apresenta a análise estatística descritiva do dataset D2, conforme o briefing da disciplina de Estatística Descritiva. O conjunto `eleicoes.csv` reúne informações sobre candidatos a Deputado Federal nas eleições brasileiras de 2014, com quatro campos centrais: UF, número do candidato, gasto de campanha e votos obtidos.

O briefing solicita quatro entregas principais para esse dataset: (i) histogramas de dinheiro e votos para três estados escolhidos pelo aluno; (ii) gráficos de dispersão entre dinheiro e votos, com o respectivo coeficiente de Pearson, para esses mesmos estados; (iii) uma tabela com a correlação por estado para o Brasil inteiro; e (iv) uma tabela-resumo por UF contendo medidas de tendência central e dispersão para dinheiro e votos.

Os estados selecionados foram **Rio de Janeiro (RJ)**, **Goiás (GO)** e **Amazonas (AM)**. A escolha busca representar três contextos comportamentais distintos observados no notebook: um estado grande e mais heterogêneo (RJ), um estado com forte concentração de recursos em poucas campanhas (GO) e um estado com a correlação mais alta entre gasto e votos em toda a base (AM).

Assim como no relatório do dataset Titanic, optou-se pelo formato de artigo científico em padrão IEEE. Esse formato favorece a organização por seções, permite comentar cada figura e tabela logo após sua apresentação e ajuda a manter o documento final legível mesmo em um conjunto de dados com forte assimetria e grande amplitude numérica.

II. Fundamentação Teórica

A. Estatística Descritiva

A estatística descritiva reúne técnicas voltadas à organização, síntese e interpretação de conjuntos de dados, sem o objetivo de inferir parâmetros populacionais. Em problemas eleitorais, ela é especialmente útil para identificar concentração de recursos, dispersão de votos e diferenças entre unidades da federação.

B. Medidas de Posição e Dispersão

Média, mediana, mínimo, máximo, desvio-padrão e quartis permitem descrever a posição central e a variabilidade das distribuições. Em bases altamente assimétricas, como a de gastos de campanha, a mediana tende a representar melhor o candidato típico, pois a média é fortemente afetada por poucos valores extremos.

C. Histogramas e Escala Logarítmica

Histogramas representam a distribuição de frequências de uma variável quantitativa por intervalos de classe. Quando a amplitude dos dados é muito grande e há cauda longa à direita, a escala logarítmica melhora a leitura do gráfico ao comprimir os valores extremos sem eliminar a percepção de concentração nas faixas mais baixas.

D. Correlação de Pearson

O coeficiente de correlação de Pearson mede a intensidade e a direção da relação linear entre duas variáveis quantitativas contínuas. Sua expressão é a seguinte:

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \cdot \sum_{i=1}^{n}(y_i - \bar{y})^2}} \quad (1)$$

Valores positivos indicam associação direta entre as variáveis; valores negativos indicam associação inversa. Neste trabalho, o coeficiente é usado para verificar em que medida campanhas com mais recursos tendem a receber mais votos em cada estado.

III. Metodologia

A. Base Utilizada e Enriquecimento

A base principal deste relatório é o arquivo `eleicoes.csv`, com 6.353 candidaturas a Deputado Federal. O notebook também integra duas bases auxiliares do TSE: a prestação de contas de despesas e o cadastro oficial de candidatos de 2014. Esse enriquecimento recupera informações como partido, situação eleitoral, gênero e raça, além de permitir validar a consistência entre o gasto agregado da base original e a soma das despesas declaradas ao TSE.

No cruzamento com as bases auxiliares, 5.392 candidaturas (84,9%) foram localizadas. Entre os candidatos com gasto positivo, apenas 4 não tiveram correspondência. Dos 5.319 casos com gasto positivo presentes nas duas fontes, 5.054 (95,0%) tiveram concordância exata entre a base principal e o valor agregado das despesas do TSE. Como o objetivo deste relatório é cumprir o briefing do D2 com clareza, essas variáveis adicionais são usadas apenas para caracterização do conjunto, enquanto as análises centrais permanecem em *Gasto* e *Votos*.

B. Filtros Analíticos

Candidatos com *Gasto* igual a zero foram removidos das análises de distribuição de gastos e das correlações. Essa decisão é metodologicamente justificada por dois motivos: (i) 1.030 candidatos (16,2% da base) não registraram gasto algum, o que criaria uma massa artificial em zero; e (ii) nenhum candidato eleito apresentou gasto zero.

Para os histogramas de votos, foram considerados apenas candidatos com *Votos* positivos. Nos gráficos de dispersão e no cálculo do coeficiente de Pearson, exigiu-se simultaneamente *Gasto* > 0 e *Votos* > 0. Na tabela-resumo por UF, cada variável foi descrita em seu domínio positivo correspondente, preservando a comparabilidade com os gráficos do notebook.

C. Procedimentos Analíticos

A análise foi organizada em quatro etapas. Primeiro, foi feita uma caracterização inicial da base e calculadas estatísticas nacionais de referência para *Gasto* e *Votos*. Em seguida, foram construídos histogramas para RJ, GO e AM, sempre com comentários curtos sobre concentração, assimetria e cauda longa. Na terceira etapa, foram gerados os gráficos de dispersão e calculadas as correlações de Pearson para esses três estados. Por fim, foram montadas duas tabelas sintéticas: uma com a correlação por UF e outra com medidas de tendência central e dispersão por estado.

IV. Resultados e Discussão

A. Caracterização Inicial e Panorama Nacional

A Tabela I resume as principais variáveis mobilizadas no relatório. Embora o dataset enriquecido contenha outros campos auxiliares, as colunas centrais para o escopo do briefing são as relacionadas à identificação da candidatura, ao gasto e ao desempenho eleitoral.

A Tabela II apresenta as estatísticas nacionais que servem de referência para a interpretação dos recortes estaduais. Em nível nacional, o gasto médio (R$ 220.397) supera a mediana (R$ 9.916) em mais de 22 vezes, enquanto a média de votos (15.286) supera a mediana (1.250) em pouco mais de 12 vezes. Em ambos os casos, a diferença entre média e mediana, aliada ao desvio-padrão elevado, já indica cauda longa à direita e forte concentração em poucos candidatos.

Esses números justificam o uso de escala logarítmica nos histogramas e nos gráficos de dispersão. Sem essa transformação visual, os poucos casos com milhões de reais em gasto ou centenas de milhares de votos comprimiriam a massa principal dos dados junto ao eixo de origem.

B. Histogramas por Estado

Para manter a leitura linear do artigo, os histogramas são apresentados individualmente, um por coluna, sempre acompanhados por um comentário curto antes e depois da figura.

1) Rio de Janeiro (RJ): O Rio de Janeiro é o maior recorte entre os três estados escolhidos, o que o torna uma boa referência para observar distribuições mais heterogêneas. Primeiro, apresenta-se o histograma do gasto de campanha.

No RJ, o gasto é fortemente assimétrico à direita: a maior parte dos candidatos aparece nas faixas mais baixas, enquanto poucos casos puxam a cauda para valores muito altos. A média é 22,7 vezes maior que a mediana, o que confirma forte concentração de recursos em poucas candidaturas.

A distribuição de votos do mesmo estado complementa esse retrato e mostra como a competitividade eleitoral também se concentra em um grupo reduzido de candidatos.

O histograma de votos do RJ também apresenta cauda longa à direita, mas com maior espalhamento visual do que nos demais estados. Isso é coerente com um colégio eleitoral maior e mais diverso, no qual há muitos candidatos com baixa votação e poucos nomes com desempenho muito superior.

2) Goiás (GO): Goiás apresenta um comportamento mais concentrado do que o RJ, sobretudo no gasto de campanha. O histograma abaixo evidencia esse padrão.

Em GO, a assimetria é a mais extrema entre os três estados analisados: a média do gasto supera a mediana em 125,7 vezes. Esse afastamento mostra que pouquíssimas campanhas concentram volume muito alto de recursos, enquanto a maioria permanece em patamares bastante modestos.

O mesmo estado também revela forte concentração na distribuição de votos, como se observa no histograma seguinte.

Tabela I: Principais variáveis analisadas no dataset D2.

Variável	Tipo	Descrição
Estado	Qualitativa nominal	UF do candidato
Numero Candidato	Qualitativa nominal	Identificador eleitoral
Gasto	Quantitativa contínua	Recursos de campanha em R$
Votos	Quantitativa discreta	Total de votos recebidos
Situacao	Qualitativa nominal	Eleito, suplente ou não eleito
Partido	Qualitativa nominal	Sigla partidária
Genero	Qualitativa nominal	Gênero declarado no TSE
Raca	Qualitativa nominal	Cor/raça declarada no TSE

Tabela II: Estatísticas descritivas nacionais das variáveis principais.

Variável	n	Média	Mediana	DP	Min	Q1	Q3	Máx
Gasto (R$)	5.323	220.397	9.916	632.549	1	2.343	77.903	8.464.594
Votos	5.741	15.286	1.250	43.372	2	399	6.701	1.524.361

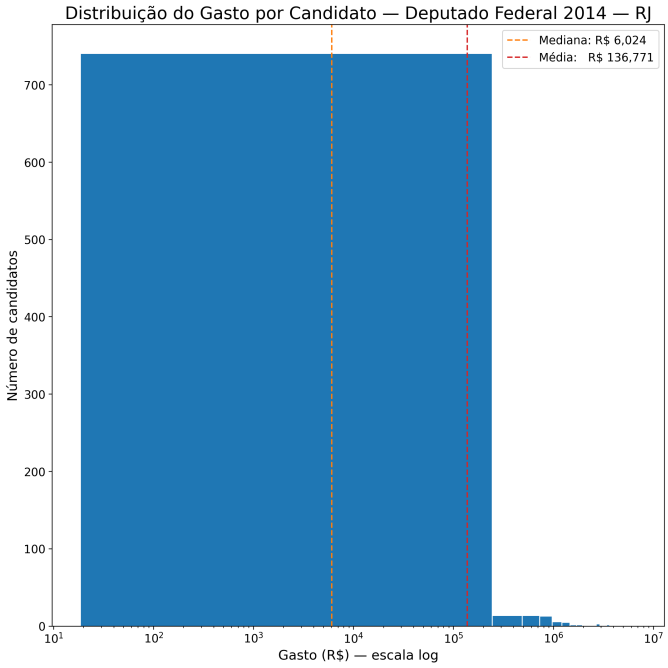

Figura 1: Histograma do gasto de campanha no Rio de Janeiro (eixo x em escala logarítmica).

Nos votos, a razão entre média e mediana chega a 25,3, sinalizando que poucos candidatos altamente competitivos dominam a distribuição. O contraste entre as barras iniciais e a longa cauda à direita deixa claro que a votação está longe de ser uniformemente distribuída.

3) Amazonas (AM): O Amazonas fecha o conjunto dos histogramas com um padrão intermediário entre RJ e GO em termos de concentração do gasto, mas com separação visual

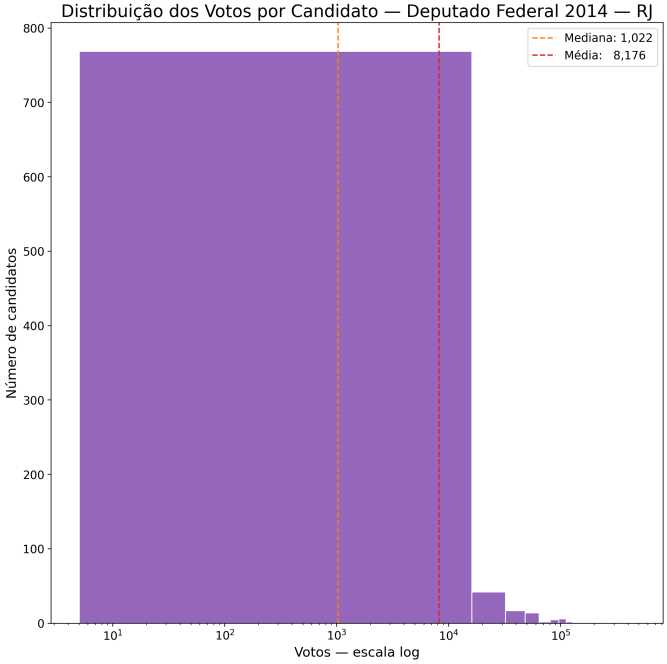

Figura 2: Histograma do número de votos no Rio de Janeiro (eixo x em escala logarítmica).

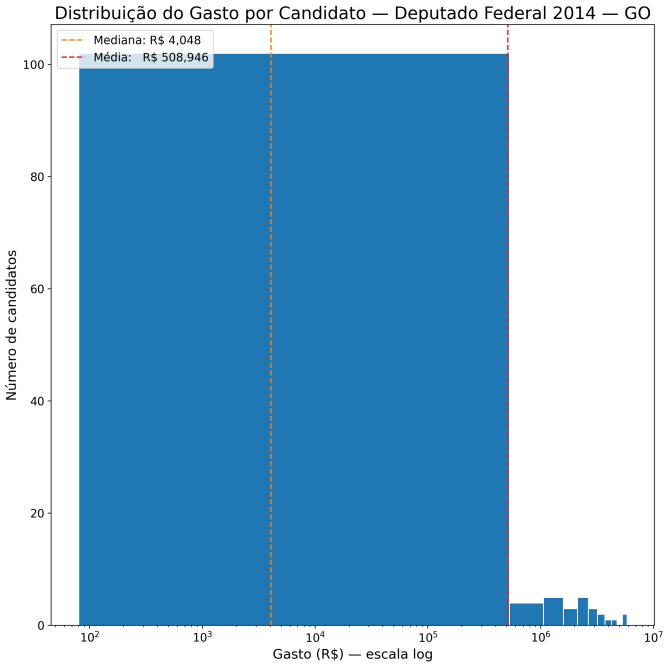

Figura 3: Histograma do gasto de campanha em Goiás (eixo x em escala logarítmica).

mais nítida entre campanhas pequenas e campanhas muito fortes.

No AM, a média do gasto é 42,7 vezes maior que a mediana. A distribuição continua fortemente assimétrica à direita, mas com um contraste visual mais claro entre a massa de campanhas de baixo gasto e o pequeno grupo de

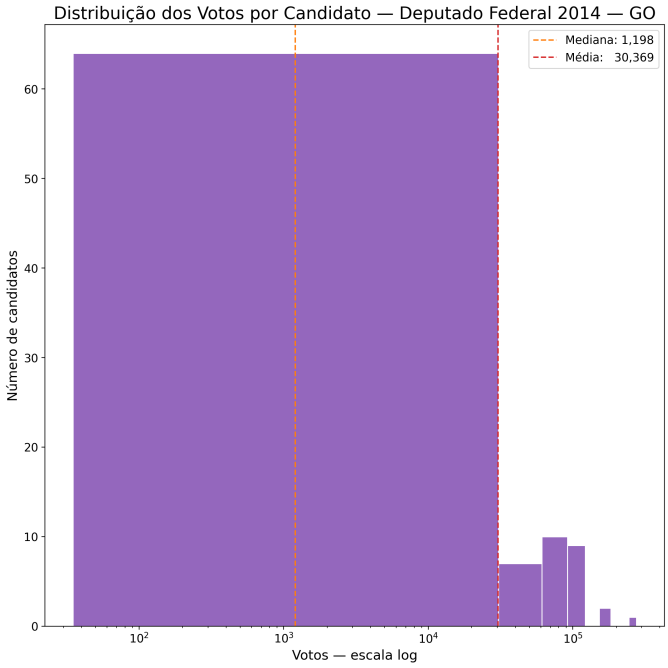

Figura 4: Histograma do número de votos em Goiás (eixo x em escala logarítmica).

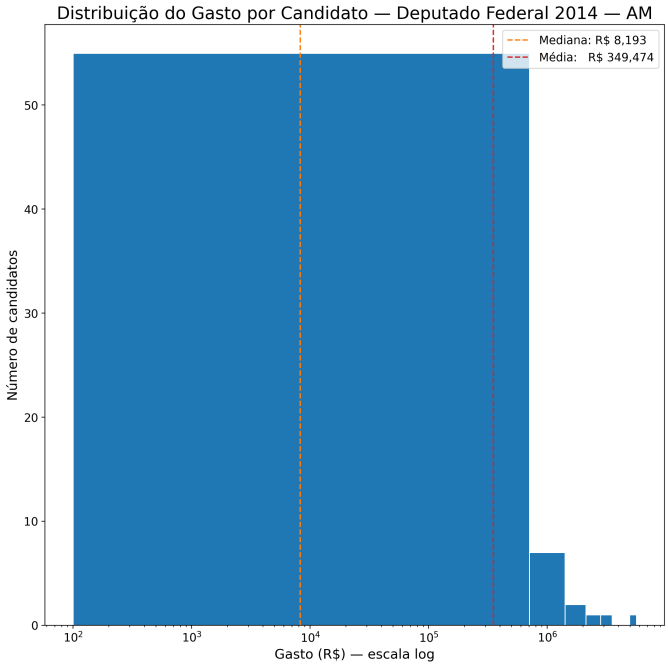

Figura 5: Histograma do gasto de campanha no Amazonas (eixo x em escala logarítmica).

candidaturas com investimento muito elevado.

Para completar o recorte amazonense, o histograma de votos mostra como essa mesma lógica aparece no desempenho eleitoral.

Os votos no AM também exibem cauda longa, mas com separação mais nítida entre os poucos candidatos muito votados

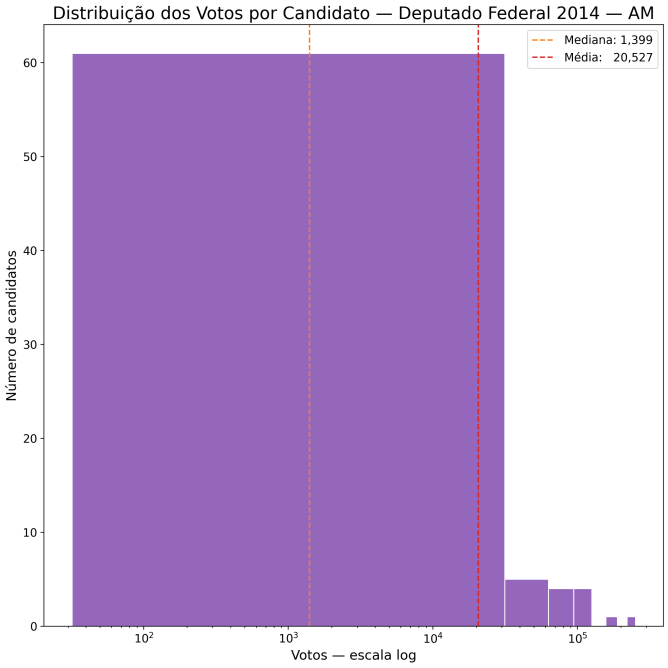

Figura 6: Histograma do número de votos no Amazonas (eixo x em escala logarítmica).

e o restante da amostra. Esse desenho antecipa a relação mais forte entre gasto e votos observada na subseção seguinte.

C. Dispersão e Correlação nos Estados Selecionados

Os gráficos de dispersão a seguir mantêm a mesma lógica de apresentação: cada figura ocupa apenas uma coluna e é imediatamente contextualizada no texto. Em todos os casos, os eixos foram mantidos em escala logarítmica para preservar a legibilidade diante da grande amplitude dos dados.

1) Rio de Janeiro (RJ): Começa-se pelo Rio de Janeiro, onde a nuvem de pontos é mais espalhada e a associação linear entre gasto e votos aparece de forma menos compacta.

No RJ, a correlação é moderada positiva ($r = 0{,}556$). A nuvem cresce da esquerda para a direita, mas ainda com bastante dispersão entre campanhas intermediárias, o que sugere relação positiva sem alinhamento tão rígido.

2) Goiás (GO): Em Goiás, a tendência visual de crescimento entre gasto e votos se torna mais evidente, embora ainda existam desvios relevantes em torno do padrão médio.

O coeficiente de Pearson em GO é $r = 0{,}605$, também classificado como moderado positivo. A inclinação geral da nuvem é clara, indicando que campanhas mais caras tendem a receber mais votos, ainda que não de forma determinística.

3) Amazonas (AM): O Amazonas encerra esta etapa com o gráfico visualmente mais organizado entre os três recortes estaduais.

No AM, a correlação é forte positiva ($r = 0{,}902$). A nuvem de pontos está mais alinhada do que em RJ e GO, o que sugere que o gasto de campanha, nesse estado, se aproxima mais de um preditor linear do total de votos.

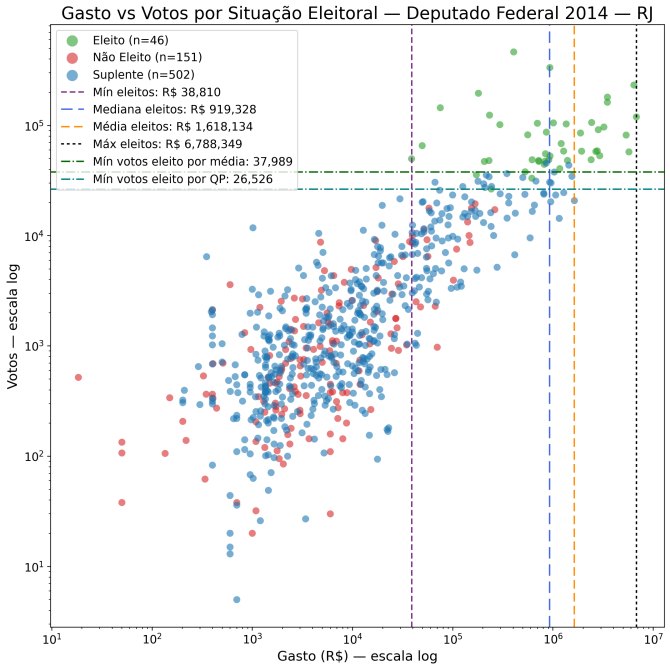

Figura 7: Dispersão entre gasto e votos no Rio de Janeiro, com eixos em escala logarítmica.

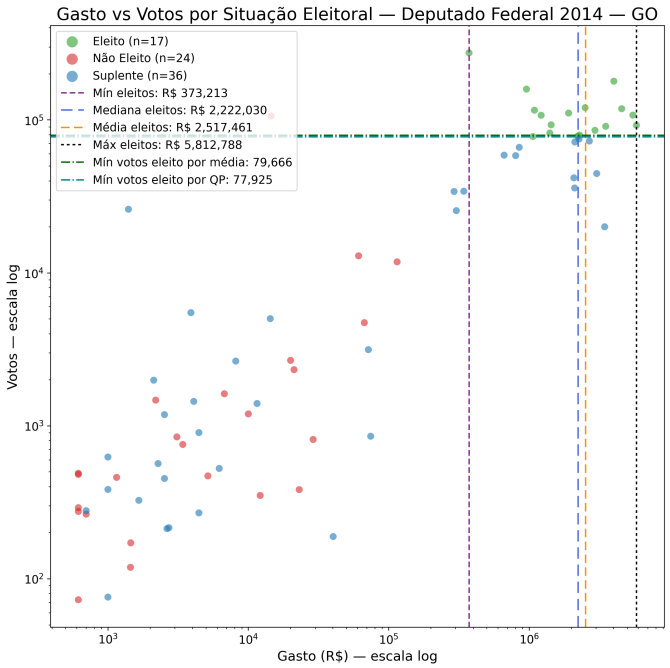

Figura 8: Dispersão entre gasto e votos em Goiás, com eixos em escala logarítmica.

A Tabela III consolida a comparação dos três estados. O contraste principal está entre o RJ, com correlação positiva mas mais difusa, e o AM, onde a associação visual e numérica é muito mais forte.

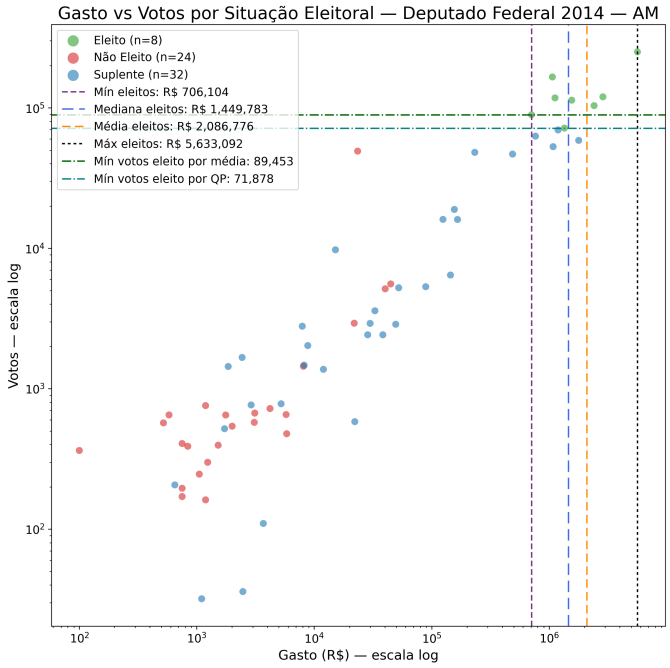

Figura 9: Dispersão entre gasto e votos no Amazonas, com eixos em escala logarítmica.

Tabela III: Coeficiente de Pearson entre gasto e votos nos estados selecionados.

UF	n	r	Leitura
RJ	701	0,556	moderada positiva
GO	77	0,605	moderada positiva
AM	64	0,902	forte positiva

D. *Correlação por Estado: Brasil Inteiro*

A Tabela IV e a Tabela V, apresentadas no Apêndice A, mostram o coeficiente de Pearson entre *Gasto* e *Votos* para todas as UFs. O resultado mais importante é que a correlação foi **positiva em todos os estados** considerados.

O Amazonas lidera o ranking com $r = 0{,}902$, seguido por Rio Grande do Norte e Santa Catarina. No extremo inferior, São Paulo apresenta o menor coeficiente ($r = 0{,}475$), ainda assim positivo. Esse contraste sugere que estados maiores e mais heterogêneos tendem a produzir relação menos linear entre gasto e votos, enquanto estados menores exibem ligação mais direta entre financiamento e desempenho eleitoral. Os três estados escolhidos para as figuras representam bem essa variação: RJ aparece próximo ao piso, GO em faixa intermediária e AM no topo da distribuição.

E. *Medidas Resumo por UF*

A descrição completa por UF foi deslocada para os apêndices em tabelas de uma coluna. As Tabelas VI e VII, no Apêndice B, reúnem o painel de votos, enquanto as Tabelas VIII e IX, no Apêndice C, reúnem o painel de gasto.

A tabela confirma um padrão recorrente ao longo do relatório: as medianas são sistematicamente inferiores às médias,

tanto para votos quanto para gasto, reforçando a presença de distribuições assimétricas. Também se nota que os rankings mudam conforme a medida observada: estados como GO, PE e TO aparecem entre os maiores gastos médios, mas isso não significa que o candidato típico nesses locais gaste mais do que em todos os outros casos. Essa diferença entre média e mediana é precisamente o efeito esperado quando poucos valores extremos dominam a distribuição.

V. Conclusão

Este relatório cumpriu os itens solicitados no briefing para o dataset D2, seguindo a mesma organização geral adotada no relatório do Titanic: breve fundamentação teórica, explicitação metodológica, apresentação dos gráficos e tabelas e comentários curtos após cada resultado.

Os dados mostram que tanto *Gasto* quanto *Votos* apresentam forte assimetria à direita. Em consequência, a mediana é uma medida mais representativa do candidato típico do que a média, principalmente em estados como Goiás e Amazonas. A escala logarítmica foi necessária para manter a legibilidade dos histogramas e gráficos de dispersão diante da grande amplitude dos valores observados.

A relação entre gasto e votos foi positiva em todas as UFs do dataset. Entre os estados selecionados, o RJ apresentou correlação moderada positiva ($r = 0{,}556$), GO também correlação moderada positiva ($r = 0{,}605$) e o AM correlação forte positiva ($r = 0{,}902$). Em termos substantivos, isso sugere que campanhas mais caras tendem a obter mais votos, embora a força dessa associação varie bastante de um contexto estadual para outro.

O notebook contém análises adicionais por partido, fornecedores, gênero e raça, mas o presente relatório privilegiou os itens diretamente exigidos na atividade e a legibilidade do PDF final. Esse recorte mantém o documento focado, sem perder os principais padrões estatísticos observados no conjunto de dados.

Apêndice A. Correlação por UF

Este primeiro apêndice reúne a correlação de Pearson entre gasto e votos para todas as unidades da federação. A divisão em duas tabelas preserva a leitura em uma coluna sem comprimir excessivamente a paginação.

Tabela IV: Correlação de Pearson entre gasto e votos por UF, parte 1.

UF	**n**	r
AM	64	0,902
RN	68	0,877
SC	104	0,865
MT	72	0,858
PB	74	0,846
RS	262	0,831
AL	79	0,829
ES	130	0,817
MG	522	0,802
MS	108	0,775
TO	42	0,760
CE	162	0,726
PR	248	0,720
PE	119	0,705

Tabela V: Correlação de Pearson entre gasto e votos por UF, parte 2.

UF	**n**	r
AC	54	0,702
PA	147	0,698
BA	212	0,674
SE	64	0,670
RO	66	0,657
MA	140	0,654
PI	76	0,644
RR	73	0,608
GO	77	0,605
AP	87	0,560
RJ	701	0,556
SP	1.072	0,475

Apêndice B. Resumo de Votos por UF

As tabelas a seguir consolidam as medidas descritivas de votos para cada estado. Mantê-las em um bloco próprio ajuda a separar a leitura desse painel do restante do anexo.

Tabela VI: Tabela-resumo por UF para votos, parte 1.

UF	Média	Mediana	DP	Min	Q1	Q3	Máx
AC	5.941	1.645	8.311	5	354	10.204	39.844
AL	12.961	1.685	28.818	13	266	6.101	135.929
AM	20.527	1.399	44.281	32	442	7.290	250.916
AP	3.608	1.083	5.187	7	250	5.609	22.134
BA	20.844	1.330	39.928	9	372	12.780	222.164
CE	20.955	1.365	46.682	15	391	6.752	277.774
ES	11.328	1.612	24.098	18	559	6.661	161.744
GO	30.369	1.198	50.073	35	383	58.466	274.625
MA	12.836	1.178	25.951	4	376	7.274	133.575
MG	15.586	1.142	38.861	13	421	5.080	310.226
MS	10.300	1.516	23.878	29	492	5.224	160.556
MT	15.522	2.581	29.416	40	414	14.096	127.749
PA	20.569	1.746	41.263	10	483	15.475	265.983

Tabela VII: Tabela-resumo por UF para votos, parte 2.

UF	Média	Mediana	DP	Min	Q1	Q3	Máx
PB	19.701	1.614	40.469	21	369	10.694	179.886
PE	27.165	2.938	50.206	5	341	23.780	283.567
PI	18.676	828	36.680	9	322	3.340	134.157
PR	18.383	1.461	39.199	8	473	11.063	200.144
RJ	8.176	1.022	28.113	5	382	3.613	464.572
RN	18.142	1.898	40.470	30	603	8.390	191.064
RO	9.147	3.216	13.884	18	884	9.315	61.419
RR	2.930	552	5.637	2	115	3.874	35.555
RS	18.037	1.455	37.144	27	487	10.924	162.462
SC	25.368	2.785	48.131	53	911	15.896	229.668
SE	13.532	980	26.748	13	280	5.611	131.236
SP	15.431	1.085	63.972	6	383	5.226	1.524.361
TO	14.585	794	21.161	67	335	28.631	75.934

APÊNDICE C. RESUMO DE GASTO POR UF

Este último apêndice apresenta as medidas descritivas do gasto de campanha por UF. A separação em página própria evita que as tabelas mais densas pareçam anexadas de forma abrupta ao fim do relatório.

Tabela VIII: Tabela-resumo por UF para gasto, parte 1.

UF	Média	Mediana	DP	Min	Q1	Q3	Máx
AC	157.044	47.348	211.815	530	5.808	237.535	736.866
AL	202.439	10.200	461.840	110	2.400	117.281	2.281.353
AM	349.474	8.193	882.444	100	1.806	134.440	5.633.092
AP	90.261	8.894	261.558	300	1.745	58.789	2.060.000
BA	303.228	12.934	748.919	1	2.045	181.737	5.979.037
CE	203.736	7.010	453.522	50	1.474	59.590	2.476.972
ES	135.353	14.343	327.745	100	4.228	62.537	2.233.582
GO	508.946	4.048	1.145.747	80	1.000	84.497	5.812.788
MA	141.318	10.982	316.186	18	1.500	127.220	2.407.218
MG	289.187	7.794	785.370	102	4.205	57.413	4.953.956
MS	260.040	42.084	623.506	656	21.150	135.628	4.298.808
MT	298.680	24.468	735.090	800	3.307	85.814	3.860.362
PA	121.643	11.977	237.400	100	1.961	112.144	1.342.770

Tabela IX: Tabela-resumo por UF para gasto, parte 2.

UF	Média	Mediana	DP	Min	Q1	Q3	Máx
PB	169.788	9.718	396.454	270	1.416	75.205	2.224.507
PE	415.384	14.922	758.170	145	5.247	480.333	3.823.108
PI	279.760	5.800	889.359	80	2.799	33.915	6.722.541
PR	261.624	11.808	670.429	100	2.593	125.899	4.779.913
RJ	136.771	6.024	565.480	18	1.650	26.452	6.788.349
RN	186.564	4.755	452.360	190	2.238	62.943	2.537.948
RO	245.899	51.306	439.389	18	10.168	354.244	2.586.063
RR	108.553	15.380	306.957	150	5.769	59.718	2.408.351
RS	209.723	12.930	500.424	5	3.150	83.590	2.906.257
SC	285.734	24.489	504.709	100	2.977	348.016	1.985.545
SE	111.915	11.267	266.889	200	2.150	42.276	1.439.636
SP	206.064	8.952	667.436	13	2.381	60.092	8.464.594
TO	354.993	23.818	581.692	250	5.643	533.039	2.489.033